

Общие сведения

Платформа обслуживает prepaid-абонентов. Файлы, поступающие с системы, содержат телеком-события абонентов, заведённых на платформе.

Заказчики

BigData

Системы-источники

PI_System — система сбора CDR-файлов с сетевых элементов подвижной связи.

Команда

- USER_A — Product Owner
- USER_B — Data Analyst
- USER_C — Backend Developer

Источники и приёмники данных

Источники (CDR в формате CSV, сжатые gzip)

Данные поступают в Kafka по топикам, соответствующим регионам:

Регион	Kafka-топик	SFTP-папка HDFS
Центр	TOPIC_MSCP_CDR_CENTRAL	Папка
Дальний Восток	TOPIC_MSCP_CDR_EAST	Папка
Сибирь	TOPIC_MSCP_CDR_SIB	Папка
Северо-Запад	TOPIC_MSCP_CDR_NW	Папка
Поволжье	TOPIC_MSCP_CDR_VOLGA	Папка
Юг	TOPIC_MSCP_CDR_SOUTH	Папка

Приёмники:

- TABLE_MSCP_RAW_KFK — необработанные CDR из Kafka (ORC)
- TABLE_MSCP_RAW_SFTP — необработанные CDR из SFTP (CSV)

Алгоритм обработки потока

Шаг 1. Фильтрация данных

Учитываются только события, произошедшие не ранее 7 дней назад и не позже 2 часов вперёд от текущего времени (на стороне обработки).

Шаг 2. Преобразования на потоке

Очистка числовых строк от лидирующих нулей:

Из этих полей удаляются лидирующие нули до первого значимого символа.

Коррекция часового пояса для временных меток:

- Для региона east: 7 часов
- Для регионов central, nw, volga, south: 3 часа

- Примечание: регион sib соответствует east.

Структура данных

Таблица: TABLE_MSCP_RAW_KFK
(из Kafka, ORC-формат, 15 полей)

Поле	Тип данных	Описание
FIELD_REGION	string	Название региона
FIELD_BIZ_DATE	date	Бизнес-дата события
FIELD_HOUR	int	Часовая партиция
FIELD_IMSI	bigint	IMSI
FIELD_CALLING_NUMBER	string	Номер вызывающего абонента
FIELD_CALLED_NUMBER	string	Номер вызываемого абонента
FIELD_CALL_START_TIME	timestamp	Время начала вызова
FIELD_CALL_END_TIME	timestamp	Время окончания вызова
FIELD_CALL_DURATION	int	Длительность вызова (сек)
FIELD_IS_ROAMING	string	Признак роуминга (true/false)
FIELD_OL_SERVICE_TYPE	tinyint	Тип сервиса
FIELD_TIME_ZONE_SHIFT	string	Сдвиг часового пояса
FIELD_TIMEZONE_CALC	int	Вычисленный сдвиг в минутах
FIELD_BALANCE	double	Текущий баланс абонента
FIELD_BALANCE_EXPIRE	timestamp	Срок истечения баланса

FAQ (обобщённо, без реальных ссылок)

Тип события (голос, SMS, данные):

Определяется по FIELD_OL_SERVICE_TYPE (см. выше).

Определение технологии связи (2G/3G/4G/5G):

Для data-трафика — по полю radioAccessTechnology.

Для голоса и SMS — косвенно: по наличию/отсутствию полей геолокации (например, CELL_ID, LAC).